PROPOSAL TUGAS AKHIR - TDXXXXX

Analisis Perilaku Konsumen pada Area Komersial berbasis *Multi-Object Tracking* pada CCTV

Danendra Galang Yugastama

NRP 5024 23 1049

Dosen Pembimbing

Ir.Arta Kusuma Hernanda, S.T., M.T.

NIP 1996202311024

Dr. Surya Sumpeno, S.T., M.Sc.

NIP 19690613199702 1 003

Program Studi Sarjana 1 (S1) Teknik Komputer

Departemen Teknik Komputer

Fakultas Teknologi Elektro dan Informatika Cerdas

Institut Teknologi Sepuluh Nopember

Surabaya

2026

[Halaman ini sengaja dikosongkan]

LEMBAR PENGESAHAN

Analisis Perilaku Konsumen pada Area Komersial berbasis *Multi-Object Tracking* pada CCTV

PROPOSAL TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat memperoleh gelar Sarjana Teknik pada Program Studi S-1
Teknik Komputer
Departemen Teknik Komputer
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember

Oleh: **Danendra Galang Yugastama**
NRP. 5024 23 1049

Disetujui Oleh:

Ir.Arta Kusuma Hernanda, S.T., M.T.
NIP: 1996202311024 (Pembimbing)

Dr. Surya Sumpeno, S.T., M.Sc.
NIP: 19690613199702 1 003 (Ko-Pembimbing)

Mengetahui,
Kepala Departemen Teknik Komputer FTEIC-ITS

Dr. Arief Kurniawan, S.T., M.T.
NIP 19740907200212 1 001

SURABAYA
Oktober, 2026

[Halaman ini sengaja dikosongkan]

ABSTRAK

Analisis Perilaku Konsumen pada Area Komersial berbasis *Multi-Object Tracking* pada CCTV

Nama Mahasiswa / NRP: **Danendra Galang Yugastama / 5024231049**
Departemen **:** **Teknik Komputer FTEIC - ITS**
Dosen Pembimbing **:** **1. Ir.Arta Kusuma Hernanda, S.T., M.T.**
2. Dr. Surya Sumpeno, S.T., M.Sc.

Abstrak

Sistem analitik video krusial bagi industri ritel untuk mengekstraksi metrik perilaku konsumen secara otomatis, seperti jumlah kunjungan, durasi singgah (*dwell time*), dan waktu antre. Namun, oklusi visual akibat kepadatan pengunjung memicu fragmentasi identitas (*identity switches*), yang mendistorsi keakuratan analitik bisnis. Mengingat tingginya skor metrik pelacakan akademik belum tentu menjamin rendahnya tingkat galat di lapangan, penelitian ini mengusulkan evaluasi komparatif empat algoritma *Multi-Object Tracking* (MOT) kontemporer: ByteTrack, BoT-SORT, OC-SORT, dan Deep OC-SORT. Evaluasi menggunakan arsitektur *Tracking-by-Detection* dengan detektor YOLO11 pada rekaman CCTV operasional nyata yang sarat oklusi. Kinerja algoritma diukur dengan membandingkan ekstraksi sistem terhadap data observasi manual (*ground truth*) dan keluaran platform komersial. Penelitian ini bertujuan mengidentifikasi algoritma paling tangguh dalam meminimalkan galat absolut (MAE) dan persentase galat (MAPE) metrik bisnis. Selain itu, penelitian ini menganalisis korelasi statistik antara capaian metrik akademik (MOTA dan IDF1) dengan presisi lapangan guna membuktikan relevansi tolok ukur teoretis terhadap kebutuhan praktis industri ritel.

Kata Kunci: ***Analitik Ritel, Identity Switches, Multi-Object Tracking, Oklusi, YOLO11.***

[Halaman ini sengaja dikosongkan]

ABSTRACT

Consumer Behavior Analysis in Commercial Areas Based on CCTV-Integrated Multi-Object Tracking

Student Name / NRP: **Danendra Galang Yugastama / 5024231049**
Department **: Computer Engineering FTEIC - ITS**
Advisor **: 1. Ir.Arta Kusuma Hernanda, S.T., M.T.**
2. Dr. Surya Sumpeno, S.T., M.Sc.

Abstract

Video analytics is increasingly crucial for the retail industry to automatically extract consumer behavior metrics such as people counting, dwell time, and queue time. However, visual occlusion from visitor density triggers identity switches, which distorts the accuracy of business metrics. Since high academic tracking metrics do not necessarily guarantee low practical errors, this research proposes a comparative evaluation of four contemporary Multi-Object Tracking (MOT) algorithms: ByteTrack, BoT-SORT, OC-SORT, and Deep OC-SORT. The evaluation utilizes a Tracking-by-Detection architecture with a YOLO11 detector on real-world operational CCTV footage with high occlusion levels. The performance of each algorithm is measured by comparing the system's output against manual observation data (ground truth) and a commercial platform. This research aims to identify the most robust tracking algorithm in minimizing Mean Absolute Error (MAE) and Mean Absolute Percentage Error (MAPE) for retail analytics. Furthermore, this study analyzes the statistical correlation between academic metrics (MOTA and IDF1) and real-world precision to prove the relevance of theoretical benchmarks to the practical needs of the retail industry.

Keywords: ***Identity Switches, Multi-Object Tracking, Occlusion, Retail Analytics, YOLO11.***

[Halaman ini sengaja dikosongkan]

DAFTAR ISI

ABSTRAK **v**

DAFTAR ISI **ix**

DAFTAR GAMBAR **xi**

DAFTAR TABEL **xiii**

1 PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 2

1.3 Batasan Masalah atau Ruang Lingkup 3

1.4 Tujuan 3

1.5 Manfaat 4

2 TINJAUAN PUSTAKA **5**

2.1 Analitik Perilaku Konsumen pada Area Komersial 5

2.2 Deteksi Objek (YOLO) 5

2.2.1 Arsitektur YOLO11 5

2.3 Multi-Object Tracking (MOT) 6

2.3.1 Paradigma Tracking-by-Detection 7

2.3.2 Tantangan Oklusi dan Fragmentasi Identitas (Identity Churn) 7

2.3.3 Algoritma Pelacakan Objek Kontemporer 7

2.4 Metrik Evaluasi Pelacakan Standar Akademik 8

2.5 State of the Art 8

2.5.1 State of the Art 8

3 METODOLOGI **1**

3.1 Diagram Alir Penelitian 1
3.2 Pengumpulan dan Persiapan Data 2
3.2.1 Sumber dan Karakteristik Data 2
3.2.2 Pembuatan Data Acuan (*Ground Truth*) 2
3.3 Arsitektur Sistem *Tracking-by-Detection* 2
3.4 Ekstraksi Metrik Perilaku Konsumen 3
3.5 Pengujian dan Evaluasi Sistem 3
3.5.1 Pengujian Kinerja Pelacakan Akademik 3
3.5.2 Pengujian Tingkat Galat Metrik Bisnis Terpadu 4
3.5.3 Analisis Korelasi Statistik 4
4 HASIL YANG DIHARAPKAN **5**
4.1 Hasil yang Diharapkan dari Penelitian 5
4.2 Hasil Pendahuluan 5
5 JADWAL PENELITIAN **7**
DAFTAR PUSTAKA **9**

DAFTAR GAMBAR

2.1 Arsitektur Jaringan YOLO11 6
2.2 Alur Paradigma *Tracking-by-Detection* pada Pemrosesan Video Ritel 7

3.1 Diagram Alir Penelitian 1
3.2 Diagram Perangkat Lunak dan Alur Paradigma *Tracking-by-Detection* 3

[Halaman ini sengaja dikosongkan]

DAFTAR TABEL

2.1 *State of the art* penelitian terkait pelacakan multi-objek dan analitik ritel 9

5.1 Tabel timeline 7

[Halaman ini sengaja dikosongkan]

BAB 1 PENDAHULUAN

1.1 Latar Belakang

Sektor industri ritel fisik (*brick-and-mortar*) terus beradaptasi mempertahankan daya saing operasional di tengah pesatnya pertumbuhan ekosistem perdagangan digital. Meskipun mayoritas transaksi belanja masyarakat masih bertumpu pada kehadiran fisik di toko, para pengelola ritel menghadapi tantangan operasional yang kian berat, mulai dari lonjakan biaya tenaga kerja, ketatnya kompetisi ruang usaha, hingga tuntutan peningkatan efisiensi layanan secara berkesinambungan. Untuk menjawab tantangan tersebut, sektor ritel modern mengalami pergeseran paradigma menuju otomasi toko pintar (*smart stores*). Salah satu pilar penentu dalam transformasi ini adalah kemampuan pengelola untuk mengekstraksi data perilaku konsumen secara akurat, terukur, dan objektif sebagai landasan pengambilan keputusan strategis.

Secara konvensional, pemahaman mengenai perilaku pengunjung di dalam toko ritel sangat bergantung pada metode manual, seperti observasi petugas, pencatatan kasir, maupun survei kepuasan pelanggan secara berkala. Namun, pendekatan konvensional tersebut memiliki kelemahan mendasar karena membutuhkan alokasi sumber daya manusia yang besar, rentan terhadap bias subjektif, serta tidak mampu menyediakan data operasional secara berkesinambungan. Penerapan teknologi sensor fisik seperti kartu identifikasi RFID atau gerbang pemindai inframerah juga menghadapi hambatan tersendiri, baik dari segi biaya investasi infrastruktur yang tinggi maupun keengganan pelanggan untuk berinteraksi dengan perangkat pemindai yang invasif. Keterbatasan instrumen tradisional tersebut mendorong urgensi adopsi teknologi visi komputer (*computer vision*) yang mampu mengolah rekaman video pengawas (CCTV) secara non-invasif untuk memantau dinamika konsumen secara pasif [1], [7].

Integrasi visi komputer pada ekosistem komersial memungkinkan sistem analitik video untuk mengekstraksi berbagai indikator kinerja utama secara otomatis dan waktu nyata. Data visual yang dihimpun dari kamera pengawas dapat dikonversi menjadi metrik perilaku yang sangat bernilai bagi pengelola toko, seperti volume kunjungan (*people counting*), tingkat kepadatan area (*occupancy*), persebaran atensi pengunjung terhadap etalase produk, hingga durasi waktu singgah (*dwell time*) pelanggan di depan rak pajang [2], [4]. Pemahaman spasial dan temporal mengenai rute penjelajahan konsumen tersebut menjadi instrumen krusial dalam mengevaluasi efektivitas tata letak gerai, mengidentifikasi produk yang paling diminati, hingga mengantisipasi penumpukan antrean transaksi pada meja pembayaran.

Akan tetapi, implementasi sistem analitik visual pada denah toko ritel skala penuh tidak dapat bertumpu hanya pada penggunaan kamera tunggal (*single-camera*). Kamera tunggal memiliki keterbatasan sudut pandang (*field-of-view*) serta menghadirkan area titik buta (*blind spots*) yang cukup luas akibat tertutup oleh partisi lorong belanja atau etalase bertingkat. Ketika seorang konsumen melangkah keluar dari cakupan satu lensa kamera, sistem pelacakan otomatis kehilangan jejak individu tersebut. Kondisi ini menuntut penerapan konfigurasi jaringan multi-kamera (*multi-camera system*) guna memperluas cakupan area pemantauan secara holistik melintasi berbagai zona yang tidak saling bertumpukan (*non-overlapping views*) [1]. Melalui sinkronisasi beberapa sudut pandang kamera, pergerakan pelanggan diharapkan dapat terus dipantau secara berkesinambungan dari pintu masuk hingga area pembayaran.

Kendati konfigurasi multi-kamera menawarkan cakupan ruang yang komprehensif, pelacakan pergerakan manusia di lingkungan komersial dunia nyata menghadirkan tantangan teknis yang sangat dinamis. Pola pergerakan konsumen di dalam toko sangat acak dan tidak terduga;

pengunjung kerap berhenti mendadak, berputar arah, atau berkumpul dalam kelompok padat di area promosi tertentu. Kondisi kepadatan ini memicu timbulnya fenomena oklusi visual, yakni situasi di mana tubuh seorang pengunjung tertutup sebagian maupun seluruhnya oleh struktur rak barang, troli belanja, atau oleh pengunjung lain yang melintas di depannya [8], [9]. Pada situasi oklusi berat, pandangan kamera terhadap target pengamatan terputus sementara waktu, sehingga sistem analitik kehilangan kesinambungan visual atas subjek yang sedang diamati.

Dampak paling mendasar yang ditimbulkan oleh oklusi visual adalah terjadinya fragmentasi identitas objek atau fenomena *identity churn* [1]. Ketika seorang pelanggan yang terhalang selama beberapa detik kembali terlihat oleh kamera, sistem pelacakan kerap gagal mengenali bahwa orang tersebut adalah subjek yang sama dengan yang terpantau sebelumnya. Alih-alih menyambung riwayat lintasan yang sudah ada, algoritma pelacak justru menetapkan nomor identitas (ID) baru kepada pelanggan tersebut. Fenomena pemutusan dan pergantian ID ini berdampak fatal terhadap keabsahan penghitungan metrik analitik bisnis. Sebagai ilustrasi, seorang pelanggan yang sebenarnya mengantre di kasir selama lima menit dapat terhitung secara keliru sebagai tiga orang berbeda yang masing-masing hanya berdiri selama satu koma lima menit, akibat tubuhnya sempat tertutup oleh pengunjung lain yang melintas. Hal ini menghasilkan laporan analitik yang salah kaprah dan merugikan pihak manajemen dalam menilai kualitas layanan antrean.

Selama ini, perkembangan literatur di bidang visi komputer dan pelacakan multi-objek (*Multi-Object Tracking*) didominasi oleh upaya peningkatan performa algoritma pada metrik evaluasi standar laboratorium, seperti *Multiple Object Tracking Accuracy* (MOTA) dan *Identification F1-Score* (IDF1) [11]. Namun, terdapat kesenjangan pengetahuan yang cukup lebar antara pencapaian teoretis di laboratorium dengan kebutuhan implementasi di lapangan. Pengujian akademik umumnya dilakukan pada dataset publik yang terisolasi dengan skenario gerak yang relatif teratur. Sangat jarang ditemukan penelitian empiris yang menguji sejauh mana keunggulan skor metrik pelacakan akademik tersebut berbanding lurus dengan ketepatan penghitungan metrik bisnis perilaku konsumen saat dihadapkan pada skenario ritel komersial yang penuh dengan oklusi dan interaksi padat. Sistem yang mencatatkan nilai akurasi pelacakan tinggi secara matematis belum tentu menjamin ketepatan penghitungan durasi *dwell time* atau waktu antre jika algoritma tersebut rentan mengalami fragmentasi identitas.

Berangkat dari kesenjangan tersebut, penelitian tugas akhir ini diarahkan untuk melakukan evaluasi komparatif secara objektif terhadap performa berbagai algoritma pelacakan multi-objek mutakhir dalam mengukur indikator perilaku konsumen pada skenario ritel fisik. Pengujian difokuskan pada ketahanan algoritma pelacakan dalam mempertahankan keutuhan identitas target di tengah kondisi oklusi yang kerap terjadi di area perbelanjaan. Melalui perbandingan langsung antara hasil keluaran sistem analitik otomatis dengan data observasi manual di lapangan (*ground truth*), penelitian ini bertujuan membuktikan relevansi korelasi antara metrik tolok ukur akademik dengan presisi metrik bisnis ritel, sekaligus mengidentifikasi pendekatan pelacakan yang paling tangguh untuk meminimalkan margin kesalahan penghitungan di lingkungan operasional nyata.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, rumusan masalah dalam penelitian tugas akhir ini adalah sebagai berikut:

1. Bagaimana tingkat akurasi pengukuran metrik perilaku konsumen, yang mencakup durasi waktu singgah (*dwell time*), waktu tunggu antrean, dan estimasi jumlah pengunjung (*counting*), menggunakan sistem analitik berbasis *Multi-Object Tracking* pada kondisi

lingkungan ritel nyata dengan tingkat kepadatan dan oklusi tinggi?

2. Algoritma pelacakan manakah di antara metode kontemporer (ByteTrack, BoT-SORT, OC-SORT, dan Deep OC-SORT) yang menghasilkan tingkat galat metrik perilaku konsumen terkecil bila dibandingkan dengan data aktual di lapangan (*ground truth*) maupun platform analitik video komersial?

3. Bagaimana derajat korelasi empiris antara capaian metrik evaluasi pelacakan standar akademik (seperti MOTA dan IDF1) dengan tingkat presisi pengukuran metrik perilaku konsumen di sektor komersial dunia nyata?

1.3 Batasan Masalah atau Ruang Lingkup

Batasan masalah dalam penelitian tugas akhir ini ditetapkan sebagai berikut:

1. Analisis pemantauan visual hanya difokuskan pada deteksi target manusia (kategori kelas *person*).

2. Arsitektur model pendeteksi objek dikunci menggunakan YOLO11 (satu versi model dan bobot tetap) sebagai variabel kontrol, sehingga variasi hasil pengujian murni mencerminkan performa algoritma pelacakan yang dievaluasi.

3. Evaluasi algoritma pelacakan multi-objek dibatasi pada empat metode mutakhir: ByteTrack, BoT-SORT, OC-SORT, dan Deep OC-SORT.

4. Pelacakan identitas konsumen ditargetkan pada interval kunjungan lokal jangka pendek (skala detik hingga menit antar-bingkai video), tanpa melibatkan re-identifikasi jangka panjang lintas hari.

5. Validasi tingkat galat sistem dievaluasi terhadap data anotasi manual (*ground truth*) dari rekaman video CCTV berdurasi 10–15 menit pada jam operasional sibuk di dua lokasi area komersial.

6. Pemrosesan data video dilakukan secara anonim demi menjaga privasi pengunjung tanpa menerapkan modul pengenalan wajah (*facial recognition*).

1.4 Tujuan

Sejalan dengan rumusan masalah yang diajukan, tujuan dari pelaksanaan penelitian tugas akhir ini adalah sebagai berikut:

1. Mengukur secara kuantitatif tingkat akurasi penghitungan metrik perilaku konsumen (durasi *dwell time*, waktu tunggu antrean, dan estimasi jumlah pengunjung) yang diproses oleh sistem analitik berbasis *Multi-Object Tracking* di bawah pengaruh gangguan oklusi pada area ritel.

2. Mengevaluasi dan menentukan algoritma pelacakan multi-objek kontemporer yang menghasilkan nilai galat terendah terhadap pengamatan manual di lapangan (*ground truth*) serta membandingkannya secara objektif dengan performa platform analitik video komersial.

3. Menganalisis derajat korelasi empiris antara capaian metrik evaluasi pelacakan standar akademik (MOTA dan IDF1) dengan tingkat validitas data analitik perilaku konsumen di lapangan guna membuktikan relevansi tolok ukur teoretis terhadap kebutuhan praktis industri.

1.5 Manfaat

Manfaat yang diharapkan dari pelaksanaan penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi teoretis dengan mengisi celah literatur terkait validitas penggunaan metrik evaluasi pelacakan konvensional (MOTA dan IDF1) sebagai prediktor keandalan metrik analitik bisnis di dunia nyata.

2. Menyediakan rekomendasi teknis berbasis bukti empiris bagi pengembang perangkat lunak maupun pelaku industri ritel dalam memilih algoritma pelacakan objek yang paling andal terhadap kendala oklusi visual dan fragmentasi identitas untuk diterapkan pada arsitektur platform analitik video pintar.

BAB 2 TINJAUAN PUSTAKA

2.1 Analitik Perilaku Konsumen pada Area Komersial

Analitik perilaku konsumen berbasis visi komputer merupakan teknologi esensial bagi industri ritel fisik untuk memahami pola interaksi pelanggan secara kuantitatif. Tiga metrik utama yang sering diukur meliputi volume kunjungan (*counting*), tingkat kepadatan area (*occupancy*), dan waktu singgah (*dwell time*). Menurut tinjauan sistematis dalam literatur visi komputer, pemanfaatan jaringan multi-kamera di sektor ritel (*smart stores*) diterapkan secara spesifik untuk memetakan arus pergerakan komersial secara efisien tanpa memerlukan identifikasi biometrik eksplisit [1]. Pemanfaatan data trajektori pelacakan konsumen melalui kamera pengawas memungkinkan pembentukan peta persebaran spasial (*heatmap*) guna mengidentifikasi zona-zona yang paling banyak dikunjungi pembeli di dalam gerai [2].

Pemahaman perilaku konsumen dapat diperdalam lebih lanjut melalui analisis arah tatapan (*gaze estimation*) berbasis pembelajaran mendalam (*deep learning*) untuk mengetahui etalase produk mana yang secara spesifik menarik perhatian pembeli [3]. Namun demikian, seluruh analisis metrik lanjutan tersebut sangat bergantung pada keandalan sistem tingkat dasar dalam mendeteksi dan melacak pergerakan pelanggan secara konsisten dari waktu ke waktu [4].

2.2 Deteksi Objek (YOLO)

Algoritma *You Only Look Once* (YOLO) merupakan arsitektur mutakhir dalam deteksi objek berbasis *Convolutional Neural Network* (CNN) yang beroperasi secara waktu nyata. Prinsip kerja YOLO didasarkan pada perlakuan deteksi sebagai masalah regresi tunggal, di mana citra masukan diproses secara langsung untuk memprediksi koordinat kotak pembatas (*bounding box*) beserta probabilitas kelas objek secara simultan. Efisiensi komputasi arsitektur CNN ringan seperti varian YOLO menjadikannya pilihan dominan untuk implementasi praktis di lingkungan komersial cerdas dibandingkan arsitektur berbasis model transformator yang membutuhkan komputasi lebih besar [1].

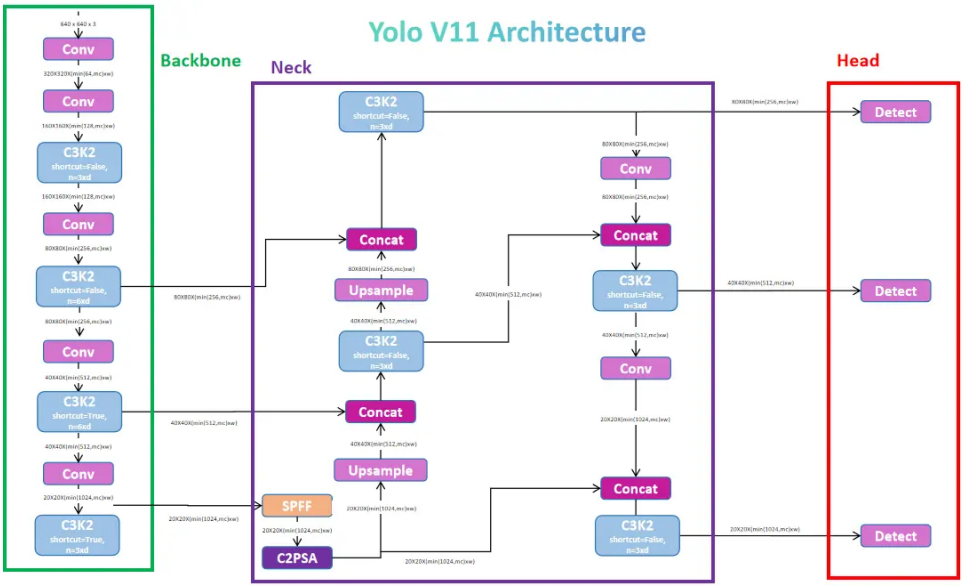
Optimalisasi model YOLO pada sektor ritel telah banyak dieksplorasi, salah satunya melalui pengembangan arsitektur LSR-YOLO yang dirancang ringan namun tetap memiliki presisi tinggi dalam mengenali produk di rak toko [5]. Modifikasi serupa diterapkan pada varian YOLO teroptimasi untuk mengenali produk ritel berukuran kecil (*small objects*) pada kabinet pajang dengan kondisi pencahayaan minim (*low-light*) [6]. Di sisi implementasi perangkat keras, model deteksi berbasis YOLO juga terbukti dapat diintegrasikan secara efektif dengan sistem mikrokontroler lokal untuk menghasilkan dasbor analitik pelanggan secara waktu nyata [7]. Dalam konteks penelitian ini, YOLO versi terbaru (YOLO11) difungsikan sebagai variabel kontrol konstan pada tahap deteksi agar seluruh variasi performa metrik murni merefleksikan keandalan algoritma pelacakan yang diuji.

2.2.1 Arsitektur YOLO11

Penelitian ini menggunakan YOLO11 (You Only Look Once versi 11) sebagai model dasar untuk tugas pendeteksian objek. YOLO11 dipilih karena mewakili state-of-the-art dalam keseimbangan antara akurasi deteksi (*mean Average Precision* / mAP) dan kecepatan inferensi (*real-time processing*), yang sangat krusial untuk implementasi analitik video beruntun pada lingkungan komersial.

Secara struktural, arsitektur YOLO11 tidak jauh berbeda dari pendahulunya, namun membawa optimasi signifikan pada ekstraksi fitur dan penanganan objek dalam berbagai skala.

Arsitektur jaringan YOLO secara umum divisualisasikan pada Gambar 2.1.



Gambar 2.1: Arsitektur Jaringan YOLO11

Secara garis besar, arsitektur YOLO11 terbagi menjadi tiga komponen utama pengekstraksi dan pemroses fitur:

1. ***Backbone*:** Merupakan bagian hulu arsitektur yang bertugas mengekstraksi fitur visual dasar dari citra input (seperti tepi, tekstur, dan bentuk). YOLO11 menggunakan modul *Convolutional Neural Network* (CNN) yang telah dioptimalkan (misalnya variasi blok C3k2 atau C2f) untuk meningkatkan kapasitas representasi fitur dengan beban komputasi yang lebih ringan.

2. ***Neck*:** Berfungsi untuk mengumpulkan dan menggabungkan fitur-fitur dari berbagai tingkat resolusi (*multi-scale feature aggregation*) yang dihasilkan oleh *Backbone*. Modul seperti *Spatial Pyramid Pooling - Fast* (SPPF) dan *Path Aggregation Network* (PANet) digunakan agar sistem mampu mendeteksi orang dengan skala ukuran yang berbeda-beda, baik yang berada di dekat kamera maupun di kejauhan.

3. ***Head*:** Merupakan lapisan terakhir yang bertanggung jawab mengubah fitur yang telah dikumpulkan menjadi prediksi konkret. *Head* memproyeksikan probabilitas kelas objek (dalam penelitian ini: kelas *person*) beserta koordinat kotak pembatas (*bounding box*) secara serentak (*dense prediction*).

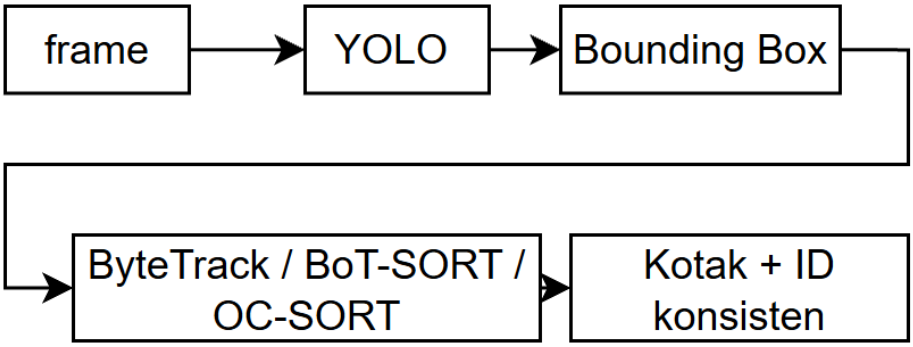
Dengan arsitektur ini, model hanya memerlukan satu kali proses komputasi meneruskan citra (*single forward pass*) untuk mendeteksi seluruh target manusia di dalam satu bingkai video, menjadikannya ideal sebagai pendeteksi stabil bagi algoritma pelacakan (*Tracker*) yang berjalan di belakangnya.

2.3 Multi-Object Tracking (MOT)

Multi-Object Tracking (MOT) merupakan proses komputasi untuk mengidentifikasi keberadaan target serta mempertahankan lintasan (*trajectory*) dari banyak objek secara berkesinambungan dalam urutan bingkai video (*video frames*).

2.3.1 Paradigma Tracking-by-Detection

Pendekatan yang paling dominan digunakan dalam sistem pelacakan modern adalah paradigma *Tracking-by-Detection* (TbD) [8]. Dalam implementasi visi komputer, sering kali timbul miskonsepsi bahwa algoritma pendeteksi (seperti YOLO) dan algoritma pelacak (seperti ByteTrack) merupakan dua metode alternatif yang saling menggantikan (pilihan A atau B). Secara fundamental, kedua komponen tersebut berada pada tingkatan fungsi yang berbeda dan bekerja secara komplementer dalam satu rangkaian alur pemrosesan (*pipeline*) berurutan, sebagaimana diilustrasikan pada Gambar 3.2.



Gambar 2.2: Alur Paradigma *Tracking-by-Detection* pada Pemrosesan Video Ritel

Modul detektor hanya bertugas melokalisasi koordinat keberadaan objek (*bounding box*) pada setiap bingkai secara independen tanpa memiliki memori temporal terhadap riwayat bingkai sebelumnya. Sebaliknya, modul pelacak (*tracker*) tidak memiliki kapabilitas untuk mendeteksi fitur objek langsung dari piksel mentah; fungsinya adalah menerima sekumpulan kotak deteksi dari detektor untuk kemudian melakukan asosiasi data (*data association*) antar-bingkai, memprediksi perpindahan posisi spasial menggunakan estimasi gerak, serta mempertahankan nomor identitas unik (*tracking ID*) dari setiap individu. Oleh karena itu, penggantian YOLO secara langsung dengan ByteTrack secara teknis tidak dapat dilakukan karena modul pelacak selalu mensyaratkan adanya modul deteksi di bawahnya.

2.3.2 Tantangan Oklusi dan Fragmentasi Identitas (Identity Churn)

Asosiasi data temporal antar-bingkai menghadapi tantangan besar pada skenario dunia nyata, terutama yang diakibatkan oleh variasi pencahayaan, kepadatan kerumunan, dan fenomena oklusi visual [1]. Oklusi terjadi ketika pandangan kamera terhadap target terhalang oleh partisi gerai, barang bawaan, maupun oleh pengunjung lain yang melintas di depannya [8], [9].

Saat target tertutup secara visual, detektor gagal menghasilkan kotak deteksi untuk beberapa bingkai. Ketika target tersebut kembali terlihat, modul pelacak standar kerap gagal menautkan target tersebut ke riwayat lintasannya yang lama dan justru memberikan nomor identitas baru. Fenomena ini disebut sebagai pergantian identitas (*identity switch*) atau fragmentasi identitas (*ID churn*) [1]. Fenomena ini merusak validitas penghitungan metrik analitik bisnis secara signifikan; sebagai contoh, satu orang pelanggan yang berdiri di depan rak display selama lima menit dapat tercatat secara keliru sebagai tiga pelanggan berbeda dengan rata-rata waktu singgah (*dwell time*) yang jauh lebih singkat dari kondisi riil.

2.3.3 Algoritma Pelacakan Objek Kontemporer

Untuk mengatasi kelemahan asosiasi data akibat oklusi, berbagai algoritma pelacakan modern dikembangkan dengan mekanisme inferensi yang berbeda:

1. **ByteTrack**: Mengajukan metode asosiasi BYTE yang memanfaatkan kotak deteksi dengan nilai kepercayaan rendah selain deteksi berskor tinggi. Strategi ini terbukti efektif mempertahankan kesinambungan lintasan target saat mengalami oklusi sebagian tanpa menambah beban komputasi ekstraksi fitur kenampakan.

2. **BoT-SORT**: Merupakan penyempurnaan dari arsitektur SORT dengan mengintegrasikan kompensasi pergerakan kamera (*Camera Motion Compensation*) serta estimasi kecepatan yang lebih stabil pada filter Kalman untuk memperkuat akurasi lokalisasi spasial.

3. **OC-SORT**: *Observation-Centric SORT* dirancang khusus untuk memulihkan lintasan setelah oklusi berkepanjangan dengan mengurangi akumulasi galat linier pada filter Kalman konvensional melalui pembaruan observasi mundur (*observation-centric recovery*).

4. **Deep OC-SORT**: Merupakan varian lanjutan dari OC-SORT yang mengombinasikan pelacakan berbasis observasi dengan modul ekstraksi fitur kenampakan (*appearance embeddings/Re-ID*) guna memperkuat keandalan asosiasi identitas saat terjadi oklusi durasi panjang di area yang padat.

2.4 Metrik Evaluasi Pelacakan Standar Akademik

Secara konvensional di lingkungan penelitian akademik, performa sistem MOT dievaluasi menggunakan tolok ukur standar berbasis matriks kesalahan:

1. **MOTA (*Multiple Object Tracking Accuracy*)**: Mengukur akurasi pelacakan secara agregat dengan mengombinasikan kesalahan deteksi positif palsu (*false positives*), deteksi tidak terdeteksi (*false negatives*), dan frekuensi pergantian identitas (*identity switches*). Karena formulasinya didominasi oleh jumlah kesalahan lokalisasi, nilai MOTA cenderung lebih sensitif terhadap performa detektor dibandingkan kemampuan mempertahankan identitas objek jangka panjang.

2. **IDF1 (*Identification F1-Score*)**: Merupakan nilai rata-rata harmonik antara presisi identifikasi dan *recall* identifikasi. Berbeda dengan MOTA, IDF1 dirancang secara spesifik untuk mengukur sejauh mana algoritma pelacak mampu mempertahankan lintasan identitas target yang konsisten sepanjang waktu pengamatan.

2.5 State of the Art

Penelitian ini dibangun di atas landasan berbagai studi terdahulu yang berfokus pada penerapan visi komputer untuk pelacakan objek dan analitik perilaku konsumen di lingkungan komersial. Untuk memperjelas posisi penelitian ini serta mengidentifikasi kesenjangan (*research gap*) yang akan diselesaikan, perbandingan dengan penelitian-penelitian sebelumnya dirangkum pada Tabel 2.1.

2.5.1 State of the Art

Penelitian ini dibangun di atas landasan berbagai studi terdahulu yang berfokus pada penerapan visi komputer untuk pelacakan objek dan analitik perilaku konsumen di lingkungan komersial. Untuk memperjelas posisi penelitian ini serta mengidentifikasi kesenjangan (*research gap*) yang akan diselesaikan, perbandingan dengan penelitian-penelitian sebelumnya dirangkum pada Tabel 2.1.

Berdasarkan Tabel 2.1, terlihat bahwa mayoritas penelitian terdahulu telah berhasil mengoptimalkan algoritma pelacakan berdasarkan evaluasi metrik akademik (MOTA, IDF1)

Tabel 2.1: *State of the art* penelitian terkait pelacakan multi-objek dan analitik ritel

Judul / Peneliti	**Metode**	**Kelebihan**	**Kekurangan dan Gap**
Advanced Customer Behavior Tracking and Heatmap Analysis with YOLOv5 and DeepSORT in Retail Environment (Shili et al., 2024)	YOLOv5, *DeepSORT*, Analisis *Heatmap*	Efektif memetakan pola pergerakan konsumen dan tingkat keterlibatan di berbagai zona ritel.	Menggunakan arsitektur pelacak generasi lama yang rentan terhadap oklusi berat; belum mengevaluasi metrik galat durasi waktu antre secara spesifik.
Demographic-Aware Multi-Object Tracking for Retail Environments (Panagos et al., 2026)	*Tracking-by-Detection*, ReID, Prediksi Demografi, LSTM	Mengurangi *ID switches* secara signifikan pada rekaman data ritel dengan kerumunan padat.	Evaluasi masih terbatas pada metrik akademik (MOTA, IDF1); belum dikorelasikan dengan tingkat galat durasi waktu antrean di kasir.
Tinjauan Sistematis Visi Komputer Multi-Kamera di Area Ritel (Fierro-Silva et al., 2026)	Komparasi arsitektur multi-kamera dan *Deep Learning*	Mampu memperluas area pemantauan pelanggan di seluruh zona toko tanpa titik buta.	Komputasi sangat berat untuk diterapkan pada *real-time deployment*; rentan kehilangan jejak (*identity churn*) saat oklusi antar-kamera.

maupun pemetaan perilaku dasar. Namun, terdapat kesenjangan (*gap*) empiris: tingginya skor akurasi pelacakan di laboratorium belum tentu mencerminkan rendahnya tingkat margin kesalahan (*error rate*) dalam menghitung metrik bisnis yang lebih kompleks (seperti *dwell time* dan waktu antre) saat berhadapan dengan oklusi berat. Penelitian ini hadir untuk mengisi kesenjangan tersebut melalui evaluasi komparatif algoritma MOT kontemporer yang diuji langsung pada skenario operasional ritel nyata.

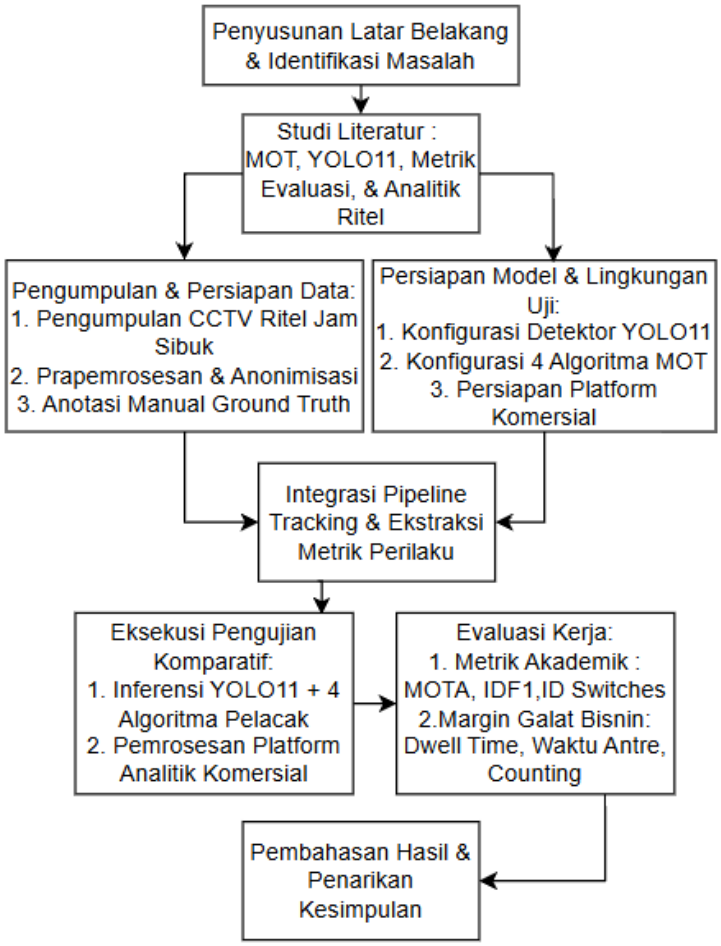
Berdasarkan Tabel 2.1, terlihat bahwa mayoritas penelitian terdahulu hanya berfokus pada optimalisasi algoritma pelacakan berdasarkan evaluasi metrik akademik standar, atau hanya berfokus pada penghitungan jumlah pengunjung sederhana. Penelitian ini mengisi kesenjangan (*gap*) tersebut dengan mengevaluasi sejauh mana algoritma pelacakan kontemporer mampu meminimalkan margin kesalahan sistem dalam mengukur metrik bisnis yang lebih kompleks, seperti durasi *dwell time* dan waktu tunggu antrean di kasir, ketika dihadapkan pada gangguan oklusi berat.

BAB 3 METODOLOGI

Bab ini menguraikan tahapan-tahapan penelitian yang dilakukan untuk menjawab rumusan masalah. Pembahasan mencakup alur penelitian, pengumpulan dan persiapan data, perancangan arsitektur sistem pelacakan, metode ekstraksi perilaku konsumen, hingga skenario pengujian dan metrik evaluasi yang digunakan.

3.1 Diagram Alir Penelitian

Diagram alir penelitian merupakan tahapan fundamental yang memetakan langkah-langkah sistematis dari awal hingga akhir penelitian. Secara umum, alur kerja dibagi menjadi persiapan data, konfigurasi sistem, eksekusi pengujian, dan analisis korelasi. Diagram alir penelitian ini dapat dilihat pada Gambar 3.1.



Gambar 3.1: Diagram Alir Penelitian

Berdasarkan Gambar 3.1, tahapan penelitian ini dapat dijelaskan secara rinci sebagai berikut:

1. **Identifikasi Masalah dan Studi Literatur**: Tahap awal untuk merumuskan batasan masalah dan mengkaji literatur terkait algoritma *Tracking-by-Detection*, arsitektur

YOLO11, serta formula metrik bisnis ritel.

2. **Pengumpulan dan Persiapan Data**: Proses perekaman video dari lingkungan ritel nyata serta pembuatan data acuan (*ground truth*) secara manual untuk indikator *dwell time*, antrean, dan *counting*.

3. **Persiapan Komponen Sistem**: Tahap mengonfigurasi variabel kontrol berupa model detektor YOLO11 dan variabel independen yang terdiri dari empat algoritma MOT (ByteTrack, BoT-SORT, OC-SORT, Deep OC-SORT).

4. **Integrasi *Pipeline***: Menyatukan modul pendeteksi, modul pelacak, dan skrip logika ekstraksi metrik konsumen ke dalam satu alur pemrosesan yang utuh.

5. **Eksekusi Pengujian Komparatif**: Menjalankan sistem yang telah dibangun pada dataset video dan membandingkan hasil keluarannya dengan platform analitik video komersial.

6. **Evaluasi dan Analisis Korelasi**: Menghitung nilai metrik akademik (MOTA, IDF1), menghitung tingkat galat nyata di lapangan (MAE, MAPE), lalu menguji korelasi statistik di antara keduanya.

3.2 Pengumpulan dan Persiapan Data

Tahap ini bertujuan untuk memperoleh data visual yang merepresentasikan kondisi operasional ritel komersial secara nyata, yang nantinya digunakan sebagai input sistem sekaligus dasar validasi pengujian.

3.2.1 Sumber dan Karakteristik Data

Data diperoleh secara langsung melalui perekaman sistem kamera pengawas (CCTV) di dua lokasi area komersial ritel. Untuk mendapatkan tingkat kepadatan dan tantangan oklusi yang representatif, pengambilan data dilakukan pada jam operasional sibuk (*rush hour*). Durasi setiap sampel video dibatasi antara 10 hingga 15 menit. Pengambilan data mempertimbangkan beberapa variasi kondisi, meliputi perbedaan tata letak etalase, variasi pencahayaan ruangan, tingkat kepadatan antrean, serta sudut pandang elevasi kamera (*oblique angle*). Seluruh proses perekaman dilakukan secara anonim tanpa melibatkan modul ekstraksi fitur wajah demi mematuhi etika privasi.

3.2.2 Pembuatan Data Acuan (*Ground Truth*)

Video mentah yang telah dikumpulkan kemudian dianotasi secara manual untuk membentuk data acuan (*ground truth*). Anotasi dilakukan dengan mencatat stempel waktu (*timestamp*) aktual pada level bingkai (*frame-level*) untuk mendata tiga parameter utama: (1) total volume pengunjung yang melewati garis virtual kasir, (2) durasi waktu singgah riil per individu di area etalase, dan (3) durasi waktu antre per individu. Data acuan ini menjadi standar emas absolut untuk mengukur margin galat sistem pelacakan otomatis nantinya.

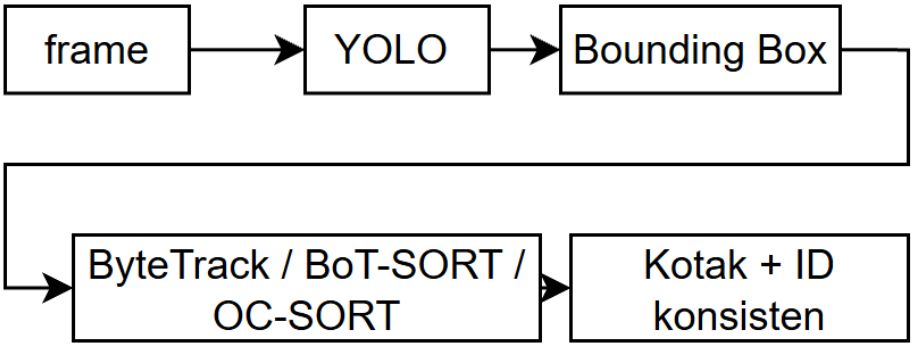
3.3 Arsitektur Sistem *Tracking-by-Detection*

Sistem pelacakan pada penelitian ini dirancang menggunakan paradigma *Tracking-by-Detection* (TbD). Alur pemrosesan data divisualisasikan pada Gambar 3.2.

Alur kerja arsitektur sistem pada Gambar **??** diuraikan sebagai berikut:

1. Sistem menerima input berupa bingkai (*frame*) video ritel secara sekuensial.

2. Setiap bingkai diproses oleh model detektor YOLO11 untuk melokalisasi target manusia dan menghasilkan koordinat kotak pembatas (*bounding boxes*).



Gambar 3.2: Diagram Perangkat Lunak dan Alur Paradigma *Tracking-by-Detection*

3. Sekumpulan kotak pembatas mentah tersebut diteruskan ke modul algoritma pelacak (salah satu dari ByteTrack, BoT-SORT, OC-SORT, atau Deep OC-SORT).

4. Algoritma pelacak melakukan asosiasi data antar-bingkai menggunakan matriks jarak (*Intersection over Union* / IoU) dan/atau filter Kalman untuk menautkan deteksi pada bingkai saat ini dengan riwayat jejak (*tracklets*) sebelumnya.

5. Sistem mengeluarkan output final berupa kotak pembatas yang telah dilengkapi dengan nomor identitas (ID) unik dan konsisten untuk setiap pengunjung.

3.4 Ekstraksi Metrik Perilaku Konsumen

Hasil keluaran berupa koordinat target beserta ID unik dari sistem MOT tidak dapat langsung dibaca sebagai metrik bisnis. Oleh karena itu, diperlukan modul logika tambahan untuk mengekstraksinya:

- **Penghitungan Pengunjung (*People Counting*):** Dihitung berdasarkan logika persilangan garis virtual (*tripwire*). Jika titik tengah koordinat kaki target dengan ID tertentu memotong garis dari arah A ke B, maka sistem akan menambahkan hitungan masuk.

- **Waktu Singgah (*Dwell Time*):** Dihitung dengan mendefinisikan poligon area ketertarikan (*Region of Interest* / ROI) pada etalase. Sistem merekam waktu (*frame*) saat ID tertentu masuk ke dalam poligon (t_{masuk}) dan waktu saat ID tersebut keluar (t_{keluar}). Durasi dikonversi ke detik berdasarkan *frame rate* video.

- **Waktu Antre (*Queue Time*):** Dihitung dari akumulasi waktu saat suatu ID berada di dalam poligon area kasir dengan kondisi perpindahan koordinat piksel yang sangat lambat di bawah ambang batas kecepatan tertentu (*statis*).

3.5 Pengujian dan Evaluasi Sistem

Pengujian dan evaluasi dilakukan untuk mengukur kinerja sistem secara komprehensif, mulai dari keandalan pelacakan di tingkat piksel hingga akurasi data bisnis.

3.5.1 Pengujian Kinerja Pelacakan Akademik

Pengujian ini bertujuan untuk mengukur ketangguhan algoritma dalam menjaga konsistensi identitas target di bawah tekanan oklusi visual. Parameter yang digunakan bertumpu pada metrik CLEAR MOT, khususnya:

- ***Multi-Object Tracking Accuracy* (MOTA):** Menilai tingkat kesalahan deteksi (positif palsu, negatif palsu) dan perpindahan identitas (*ID switches*).
- ***Identification F1-Score* (IDF1):** Mengukur seberapa lama algoritma mampu mempertahankan satu ID yang sama pada target yang benar secara berkesinambungan.

3.5.2 Pengujian Tingkat Galat Metrik Bisnis Terpadu

Pengujian ini mengevaluasi kinerja sistem setelah modul ekstraksi perilaku diintegrasikan. Output sistem dibandingkan secara langsung dengan *ground truth* manual untuk mengukur penyimpangan (*error*) di dunia nyata. Metrik galat yang diukur meliputi *Mean Absolute Error* (MAE) untuk deviasi durasi *dwell time* dan antrean (dalam satuan detik), serta *Mean Absolute Percentage Error* (MAPE) untuk persentase galat pada penghitungan jumlah orang.

3.5.3 Analisis Korelasi Statistik

Tahap evaluasi akhir dilakukan dengan menganalisis hasil pengujian menggunakan uji korelasi statistik (Pearson atau Spearman). Analisis ini digunakan untuk mengetahui derajat hubungan empiris antara tingginya skor metrik akademik (MOTA/IDF1) dengan rendahnya nilai galat (MAE/MAPE) pada metrik perilaku konsumen di lapangan. Hasil evaluasi ini akan menjadi dasar identifikasi keterbatasan sistem serta penarikan kesimpulan penelitian.

BAB 4 HASIL YANG DIHARAPKAN

4.1 Hasil yang Diharapkan dari Penelitian

Dari penelitian yang akan dilakukan, diharapkan Nulla in ipsum. Praesent eros nulla, congue vitae, euismod ut, commodo a, wisi. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Aenean nonummy magna non leo. Sed felis erat, ullamcorper in, dictum non, ultricies ut, lectus. Proin vel arcu a odio lobortis euismod. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Proin ut est. Aliquam odio. Pellentesque massa turpis, cursus eu, euismod nec, tempor congue, nulla. Duis viverra gravida mauris. Cras tincidunt. Curabitur eros ligula, varius ut, pulvinar in, cursus faucibus, augue.

4.2 Hasil Pendahuluan

Sampai saat ini, kami telah Nulla mattis luctus nulla. Duis commodo velit at leo. Aliquam vulputate magna et leo. Nam vestibulum ullamcorper leo. Vestibulum condimentum rutrum mauris. Donec id mauris. Morbi molestie justo et pede. Vivamus eget turpis sed nisl cursus tempor. Curabitur mollis sapien condimentum nunc. In wisi nisl, malesuada at, dignissim sit amet, lobortis in, odio. Aenean consequat arcu a ante. Pellentesque porta elit sit amet orci. Etiam at turpis nec elit ultricies imperdiet. Nulla facilisi. In hac habitasse platea dictumst. Suspendisse viverra aliquam risus. Nullam pede justo, molestie nonummy, scelerisque eu, facilisis vel, arcu.

[Halaman ini sengaja dikosongkan]

BAB 5 JADWAL PENELITIAN

Tabel 5.1: Tabel timeline

Kegiatan	Minggu															
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Pengambilan data																
Pengolahan data																
Analisa data																
Evaluasi penelitian																

Pada *timeline* yang tertera di Tabel 5.1 Suspendisse vitae elit. Aliquam arcu neque, ornare in, ullamcorper quis, commodo eu, libero. Fusce sagittis erat at erat tristique mollis. Maecenas sapien libero, molestie et, lobortis in, sodales eget, dui. Morbi ultrices rutrum lorem. Nam elementum ullamcorper leo. Morbi dui. Aliquam sagittis. Nunc placerat. Pellentesque tristique sodales est. Maecenas imperdiet lacinia velit. Cras non urna. Morbi eros pede, suscipit ac, varius vel, egestas non, eros. Praesent malesuada, diam id pretium elementum, eros sem dictum tortor, vel consectetuer odio sem sed wisi.

[Halaman ini sengaja dikosongkan]

DAFTAR PUSTAKA

[1] C. J. Fierro-Silva, C. Del-Valle-Soto, S. M. Mostafa, and J. Varela-Aldás, "Recent advances in multi-camera computer vision for industry 4.0 and smart cities: A systematic review," *Algorithms*, vol. 19, no. 4, p. 249, 2026.

[2] G. Narvilas, V. Urbonas, and E. Butkevičiūtė, "Human's behavior tracking in a store using multiple security cameras," *Baltic Journal of Modern Computing*, vol. 10, no. 3, pp. 526–544, 2022.

[3] S. Senarath, P. Pathirana, D. Meedeniya, and S. Jayarathna, "Customer gaze estimation in retail using deep learning," *IEEE Access*, vol. 10, pp. 64 904–64 916, 2022.

[4] M. Shili, S. Jayasingh, and S. Hammedi, "Advanced customer behavior tracking and heatmap analysis with yolov5 and deepsort in retail environment," *Electronics*, vol. 13, no. 23, p. 4730, 2024.

[5] Y. Zhao et al., "Lsr-yolo: A lightweight and fast model for retail products detection," *PLOS One*, vol. 20, no. 10, e0334216, 2025.

[6] M. Yang, J. Cai, Y. Yang, J. Chen, and K. Xie, "Real-time small retail product detection in low-light intelligent cabinets under complex backgrounds," *Sensors*, vol. 26, no. 10, p. 3264, 2026.

[7] L. H. Hairurizal, R. Rifin, S. M. A. Mokhtar, M. Z. Hussin, and K. A. Kadiran, "Customer detection and tracking using computer vision, yolo, and hardware integration: A retail analytics approach," *Journal of ASIAN Scientific Research*, vol. 6, no. 1, p. 173, 2026.

[8] I.-I. Panagos et al., "Demographic-aware multi-object tracking for retail environments via temporal consistency and joint association," *Electronics*, vol. 15, no. 14, p. 3089, 2026.

[9] D. Mendes, S. Correia, P. Jorge, T. Brandão, P. Arriaga, and L. Nunes, "Multi-camera person re-identification based on trajectory data," *Applied Sciences*, vol. 13, no. 20, p. 11 578, 2023.

[10] M. Shili, O. Sohaib, and S. Hammedi, "You only look once version 5 and deep simple online and real-time tracking algorithms for real-time customer behavior tracking and retail optimization," *Algorithms*, vol. 17, no. 11, p. 525, 2024.

[11] E. Bayraktar, "Retrackvlm: Transformer-enhanced multi-object tracking with cross-modal embeddings and zero-shot re-identification integration," *Applied Sciences*, vol. 15, no. 4, p. 1907, 2025.